Dokumentasi Proyek Akhir

IFB-307 – Information Retrieval System

TA 2025-2026

Perancangan aplikasi Habit Tracker

Disusun oleh

Kelompok 3

(152023156) Muhammad Yusuf Islam
(152023157) Reynal Toeloes Ritonga



Prodi Informatika

Fakultas Teknologi Industri

Institut Teknologi Nasional

Bandung

2026

1. System Overview

1.1 Background

Perkembangan informasi digital saat ini, terutama di situs-situs berita online, membuat dokumen teks bertambah dengan sangat pesat. Akibatnya, pengguna jadi kesulitan untuk menemukan informasi yang mereka butuhkan secara cepat dan tepat dari tumpukan dokumen yang begitu banyak. Kalau kita lihat dataset BBC News misalnya, di sana ada ratusan dokumen teks dengan berbagai topik mulai dari business, sport, politics, technology, sampai entertainment. Mencari informasi secara manual dari kumpulan data sebesar itu jelas sangat tidak efisien.

Untuk mengatasi masalah ini, sistem Information Retrieval (IR) bisa menjadi solusinya. Sistem IR membantu pengguna menemukan dokumen yang paling sesuai dengan query teks yang mereka masukkan. Di proyek ini, kami mengembangkan sistem IR yang sederhana tapi cukup lengkap fiturnya untuk melakukan pencarian pada dokumen berita BBC News dalam format .txt. Sistem yang kami bangun ini menerapkan beberapa komponen penting seperti preprocessing teks, inverted index, dua model IR yaitu TF-IDF dan BM25, pemeringkatan dokumen hasil pencarian, seleksi fitur, plus ada juga fitur peringkasan dokumen secara extractive.

1.2 System Objective

Tujuan utama dari sistem ini adalah:

1. Menyediakan sistem pencarian dokumen teks berbasis query
2. Menampilkan dokumen berita yang paling relevan terhadap query pengguna
3. Membandingkan performa dua model IR populer, yaitu TF-IDF dan BM25
4. Menyajikan ringkasan isi dokumen untuk membantu pengguna memahami konten dengan cepat

Output yang diharapkan adalah daftar dokumen terurut berdasarkan tingkat relevansi, dilengkapi skor relevansi, fitur kata penting, dan ringkasan dokumen.

1.3 Scope & Limitation

Scope sistem:

- Dataset berupa ≥500 dokumen teks berita BBC News (.txt)
- Bahasa dokumen: Bahasa Inggris
- Model IR: TF-IDF + Cosine Similarity dan BM25
- Summarization: Extractive summarization

Limitasi sistem:

- Tidak menggunakan semantic search berbasis embedding
- Relevansi dievaluasi secara heuristik (berdasarkan kategori dominan)
- Tidak menggunakan learning-to-rank

2. System Overview

2.1 Functional Requirements

- FR-01: Sistem menerima query teks dari pengguna.
- FR-02: Sistem melakukan preprocessing pada query dan dokumen.
- FR-03: Sistem membangun inverted index dari dokumen.
- FR-04: Sistem melakukan pencarian menggunakan TF-IDF + Cosine Similarity.
- FR-05: Sistem melakukan pencarian menggunakan BM25.
- FR-06: Sistem menampilkan hasil ranking dokumen
- FR-07: Sistem menampilkan ringkasan dokumen (extractive)
- FR-08: Sistem menampilkan fitur kata utama dokumen

2.2 Non-Functional Requirements

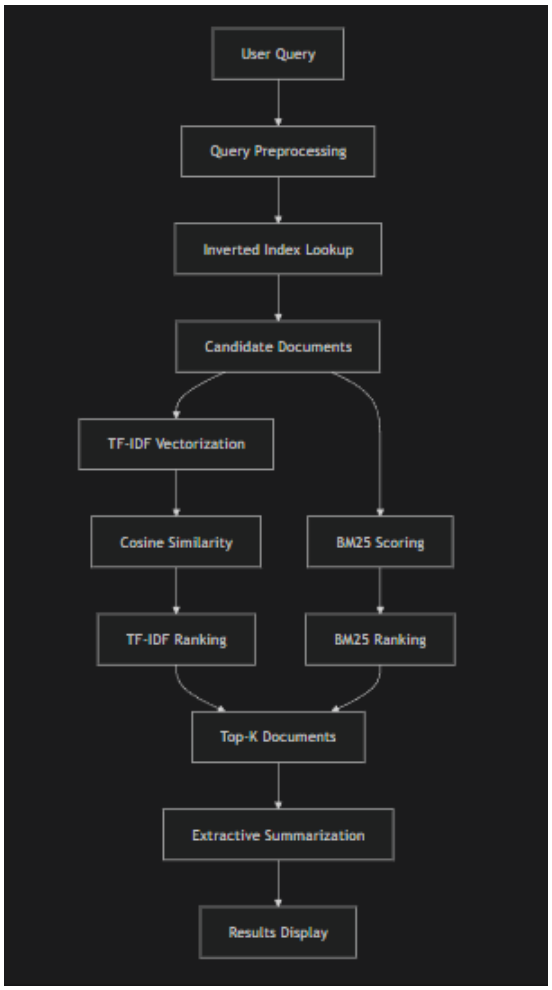
- NFR-01: Waktu respon sistem kurang dari 3 detik.
- NFR-02: Sistem mampu memproses ≥500 dokumen
- NFR-03: Sistem dapat dijalankan ulang secara konsisten (reproducible).
- NFR-04: Antarmuka mudah digunakan

3. System Architecture

3.1 Architecture Overview

Sistem IR ini menggunakan arsitektur pipeline linier. Alur kerja sistem dimulai dari input query pengguna, dilanjutkan dengan preprocessing, pemilihan kandidat dokumen melalui inverted index, perhitungan relevansi menggunakan model IR, dan diakhiri dengan penyajian hasil berupa ranking dan ringkasan dokumen.

Berikut adalah diagram pipeline Information Retrieval yang digunakan pada sistem ini:



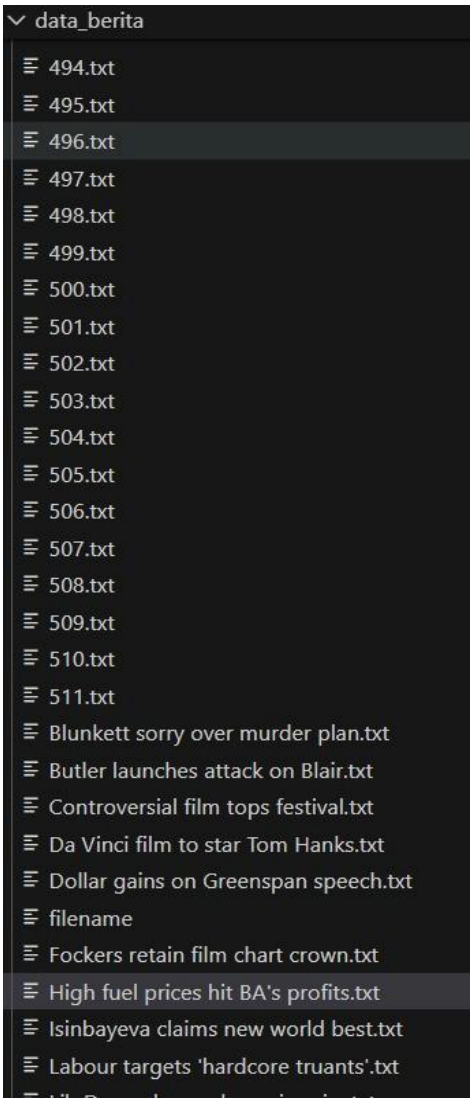
3.2 Component Description

- Data Ingestion: Membaca file .txt dari folder dataset
- Preprocessing: Tokenization, stopword removal, dan stemming
- Inverted Index: Struktur data untuk memetakan term ke dokumen
- IR Model: TF-IDF + Cosine Similarity dan BM25
- Feature Selection: Pemilihan kata penting berbasis bobot TF-IDF
- Summarization: Ringkasan dokumen berbasis kalimat dengan skor TF-IDF
- Interface: Antarmuka berbasis Streamlit

4. Data Specification

- Sumber Data: BBC News Dataset (dataset publik)
- Jumlah Dokumen: >500 dokumen
- Format Data: File teks (.txt)
- Struktur Dokumen: Judul di baris awal, diikuti isi berita
- Etika & Lisensi: Dataset publik, digunakan untuk keperluan akademik

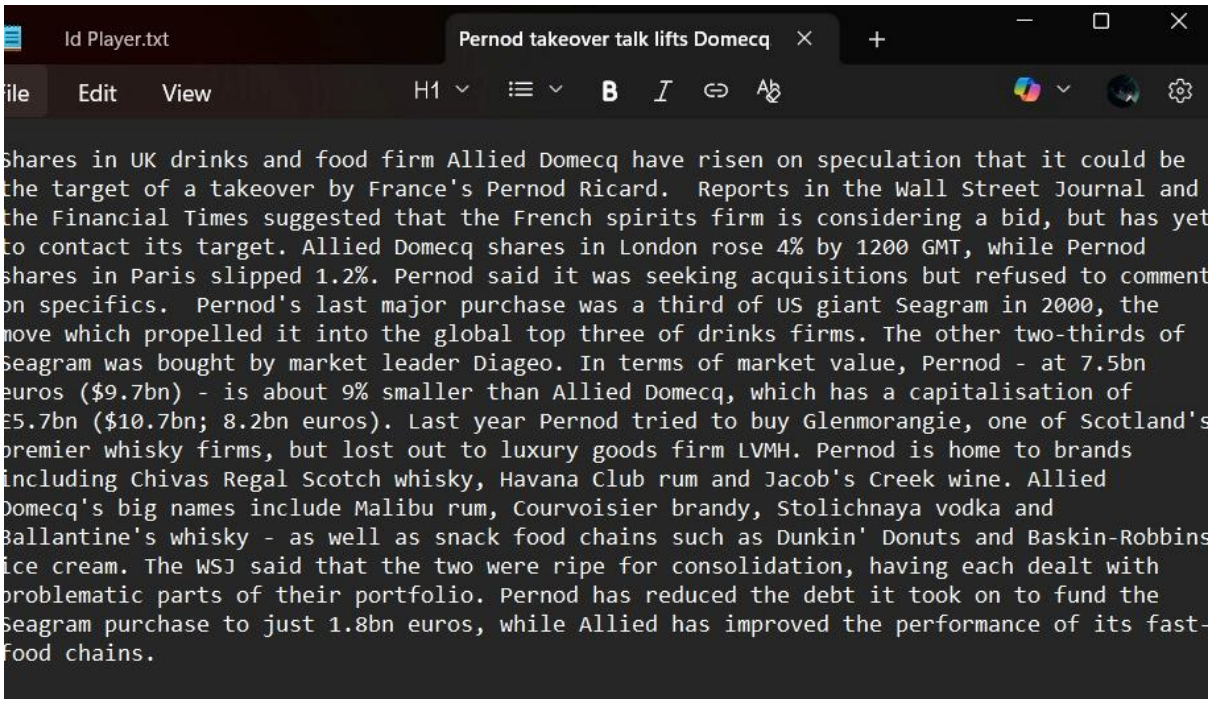
4.1 Struktur dataset



Gambar 4.1 struktur folder dataset

Gambar 4.1 menunjukkan struktur folder dataset yang digunakan dalam sistem Information Retrieval. Dataset terdiri dari lebih dari 500 dokumen berita dalam format file teks (.txt), yang disimpan dalam satu direktori. Setiap file merepresentasikan satu dokumen berita dari BBC News dengan topik yang beragam seperti bisnis, politik, teknologi, dan hiburan. Struktur dataset ini memudahkan proses data ingestion dan pemrosesan dokumen secara otomatis oleh sistem.

4.2 Contoh Isi Dokumen Dataset(.txt)



Gambar 4.2 isi dokumen dataset

5. Text Processing & Indexing Design

5.1 Text Preprocessing

Tahapan preprocessing:

1. Case folding (huruf kecil)
2. Pembersihan karakter non-alfabet
3. Tokenization
4. Stopword removal (NLTK English stopwords)
5. Stemming (Porter Stemmer)

Preprocessing bertujuan mengurangi noise dan menyamakan representasi kata.

5.2 Inverted Index Design

Inverted index menggunakan struktur dictionary(term → set(doc_id)). Struktur ini mempercepat pencarian dengan membatasi dokumen kandidat yang relevan terhadap query.

6. Information Retrieval Model Design

Model IR yang dipakai di sistem ini ada dua macam. Yang pertama TF-IDF digabung dengan cosine similarity, ini yang jadi model utama. Terus yang kedua BM25, fungsinya buat pembanding aja.

6.1 TF-IDF + Cosine Similarity

Dokumen direpresentasikan sebagai vektor TF-IDF. Query juga diubah menjadi vektor TF-IDF, kemudian dihitung cosine similarity untuk mengukur kedekatan dokumen terhadap query.

6.1 BM25 Retrieval Model

Sistem ini juga menggunakan BM25 sebagai model probabilistik selain TF-IDF yang sudah dijelaskan sebelumnya. Kalau TF-IDF hanya fokus pada bobot term, BM25 punya pendekatan yang lebih lengkap. Model ini memperhitungkan beberapa faktor seperti frekuensi kemunculan term, panjang dari dokumen tersebut, dan parameter normalisasi. Dengan begitu, skor relevansi yang dihasilkan bisa lebih menyesuaikan dengan dokumen-dokumen yang panjangnya beda-beda.

Penggunaan BM25 di sini sebenarnya untuk keperluan perbandingan dengan TF-IDF. Dari perbandingan kedua model ini, bisa dilihat kualitas hasil pencarian dari dua sudut pandang yang berbeda. Untuk proses ranking sendiri, dokumen akan diurutkan mulai dari yang memiliki skor BM25 paling tinggi ke yang paling rendah.

7. Feature Selection & Summarization Design

7.1 Feature Selection

Proses seleksi fitur dilakukan dengan memanfaatkan karakteristik TF-IDF itu sendiri. Karena term dengan bobot rendah hampir tidak memberikan pengaruh signifikan pada hasil perhitungan relevansi, maka dimensi fitur yang benar-benar bekerja jadi lebih efisien tanpa perlu dilakukan filtering manual.

7.2 Document Summarization

Metode summarization yang digunakan adalah extractive summarization. Dokumen dipecah menjadi beberapa kalimat, kemudian setiap kalimat diberi skor berdasarkan TF-IDF. Kalimat dengan skor tertinggi dipilih sebagai ringkasan.

8. Implementation Overview

8.1 Bahasa Pemrograman

Untuk implementasinya, sistem IR ini dibangun pakai Python. Karena library-nya sangat mendukung untuk pemrosesan teks dan information retrieval. Selain itu, Python juga memudahkan proses development dan cocok untuk demo sistem seperti ini dan juga menggunakan streamlit untuk mengembangkan webnya.

8.2 Library Utama

Library utama yang digunakan dalam sistem ini adalah:

- **pandas**: Digunakan untuk membaca dan memproses dataset berbentuk CSV.
- **nltk**: Digunakan untuk preprocessing teks, khususnya stopword removal dan stemming.
- **scikit-learn**: Digunakan untuk TF-IDF vectorization dan perhitungan cosine similarity.
- **rank-bm25**: Digunakan untuk implementasi model retrieval BM25.
- **re (Regular Expression)**: Digunakan untuk pembersihan teks dan pemisahan kalimat.
- **Streamlit**

8.3 Struktur Folder Proyek

Struktur folder proyek dirancang sederhana agar mudah dijalankan dan direproduksi:

```
project-ir/
├── data_berita
│       ├──001.txt
│       ├──002.txt
│       ├──003.txt
│       ├──……txt
├── bbc-news-data.csv
│
├── app.py
```

8.4 Cara Menjalankan Sistem

Langkah-langkah menjalankan sistem adalah sebagai berikut:

1. Install dependency
2. Jalankan streamlit run app.py

8.5 Alur Implementasi

Berikut merupakan alur implementasi sistem kami :

- Load dataset dokumen teks (.txt) BBC News
- Preprocess seluruh dokumen (case folding, tokenization, stopword removal, stemming)
- Membangun inverted index dari seluruh dokumen
- Membangun representasi fitur teks menggunakan TF-IDF
- Membangun model BM25 sebagai pembanding
- Input query dari pengguna
- Preprocess query (tahapan sama seperti dokumen)
- Seleksi dokumen kandidat menggunakan inverted index
- Menghitung skor kemiripan TF-IDF + cosine similarity
- Menghitung skor relevansi menggunakan BM25
- Melakukan perangkingan dokumen berdasarkan skor
- Mengambil Top-K dokumen paling relevan
- Melakukan extractive text summarization pada dokumen teratas
- Menghitung metrik evaluasi (Precision@K dan MRR)
- Menampilkan hasil pencarian, ringkasan, dan evaluasi ke pengguna

9. System Testing & Demonstration

9.1 Skenario Pengujian

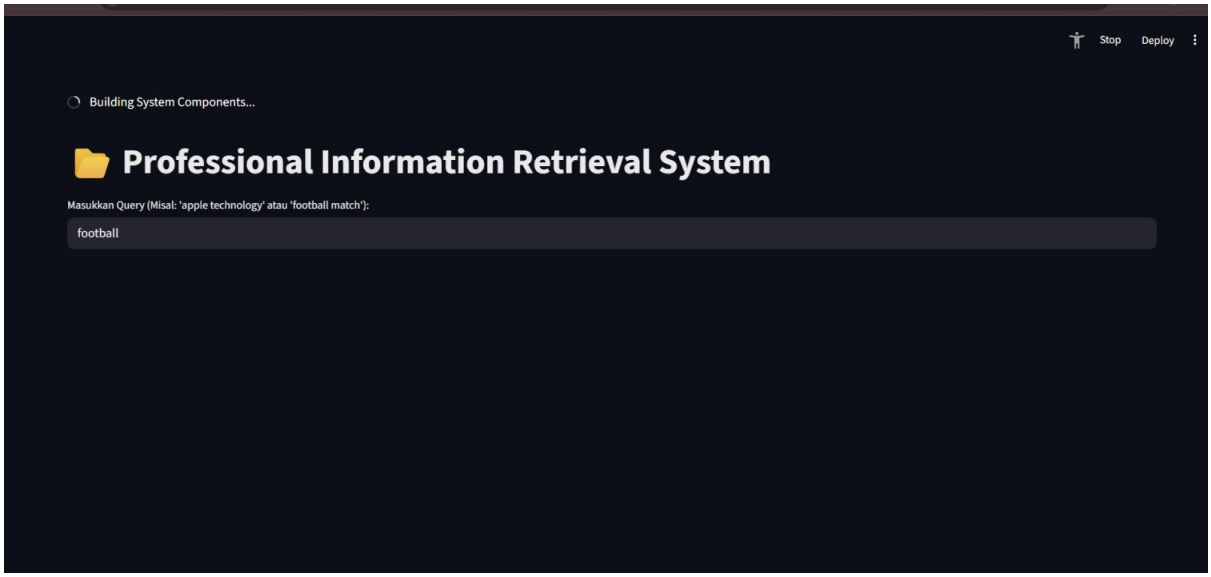
Pengujian sistem dilakukan untuk memastikan seluruh fungsi utama berjalan sesuai kebutuhan. Skenario pengujian yang digunakan meliputi:

1. Pengujian input query teks sederhana.
2. Pengujian query dengan lebih dari satu kata.
3. Pengujian hasil ranking dokumen.

4. Pengujian tampilan ringkasan dokumen.
5. Pengujian perbandingan hasil TF-IDF dan BM25.

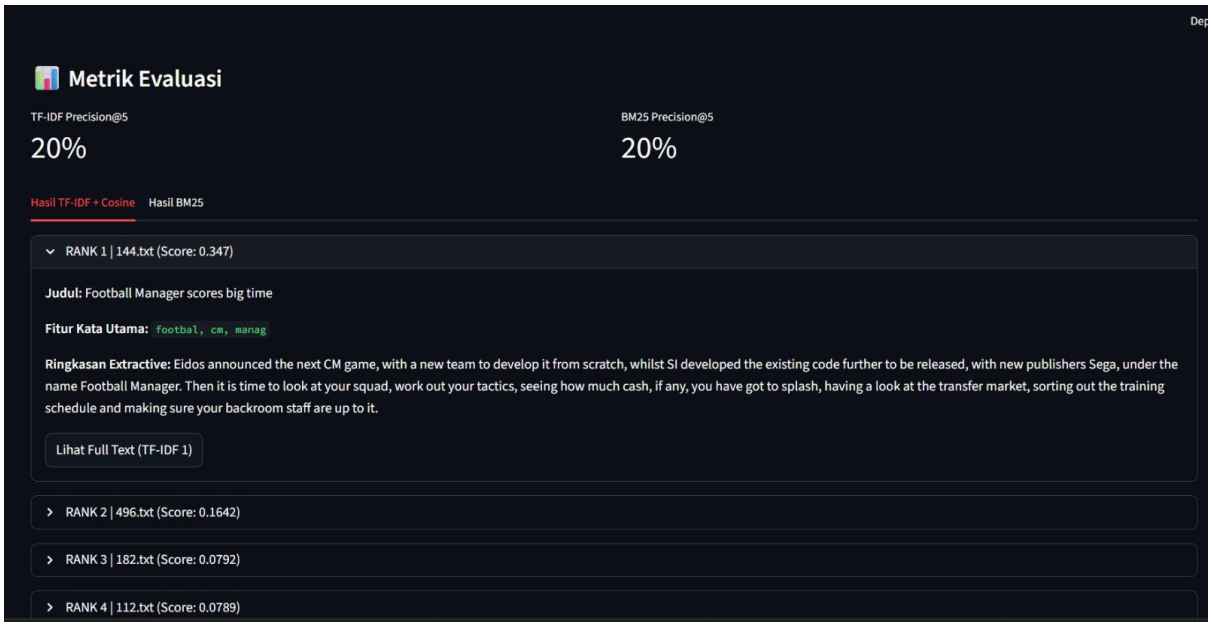
9.2 Contoh Query dan Output

Contoh query yang digunakan dalam pengujian:

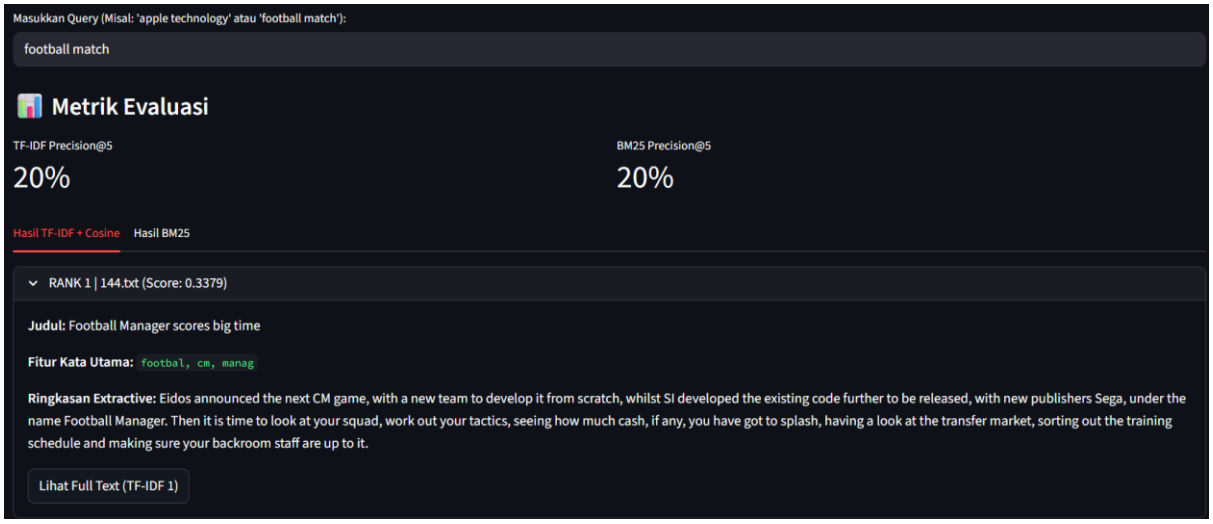


Gambar 9.2 Pencarian menggunakan query sederhana

Sistem kemudian menampilkan hasil sebagai berikut:



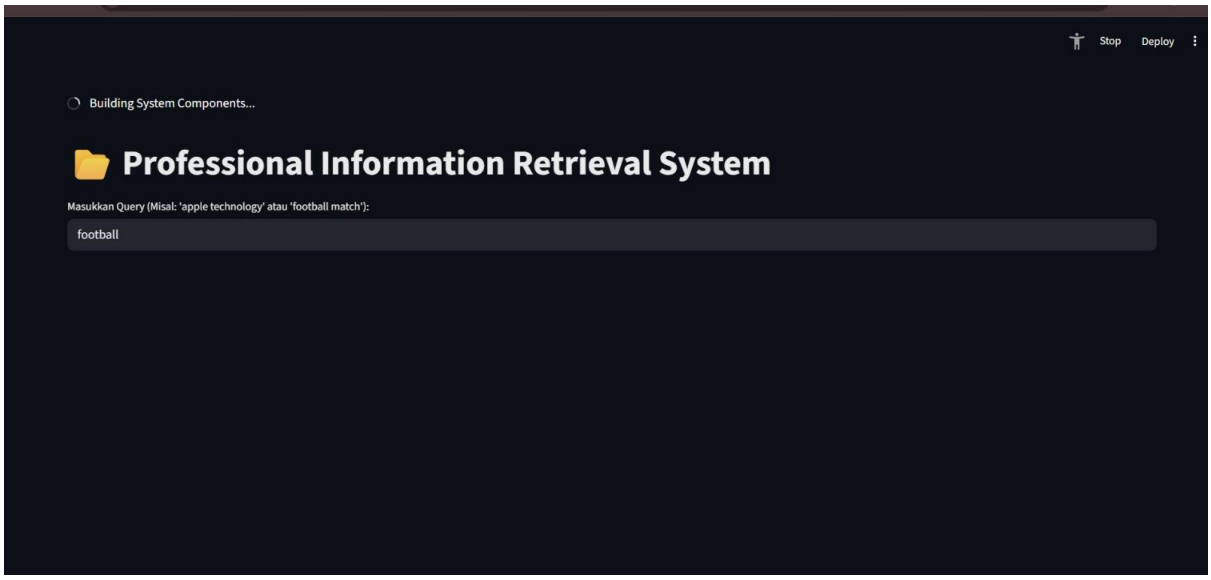
Gambar 9.2 Hasil Pencarian Menggunakan Query Sederhana



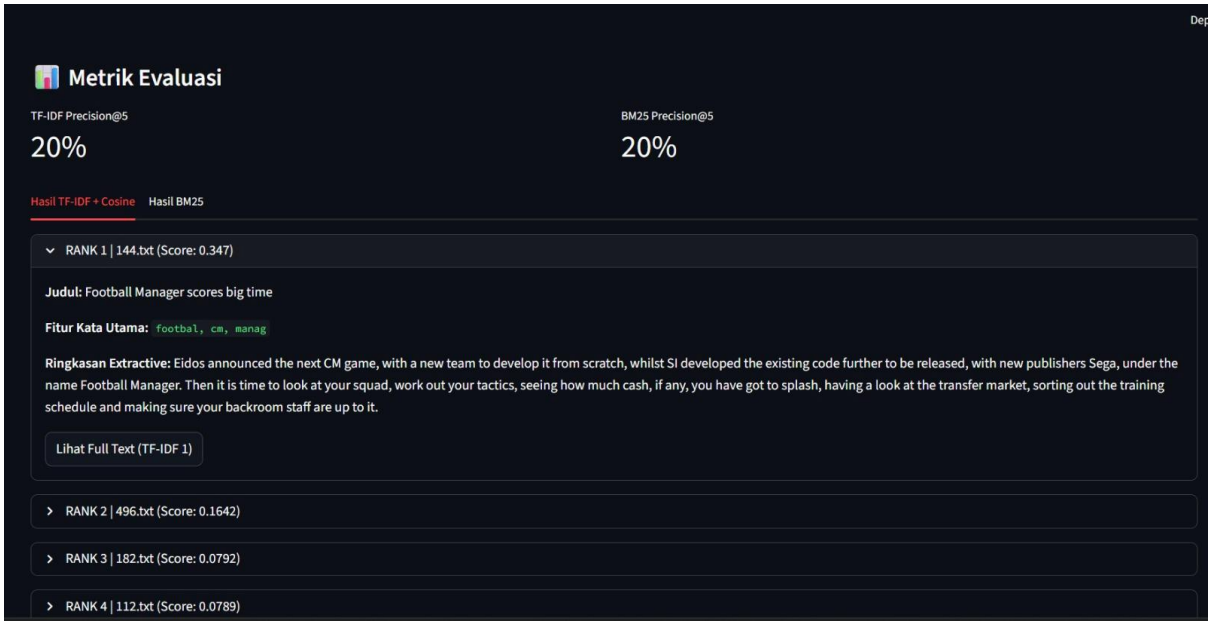
Gambar 9.2 Hasil Pencarian Menggunakan Query Lebih dari 1 Kata

9.3 Demonstrasi Sistem

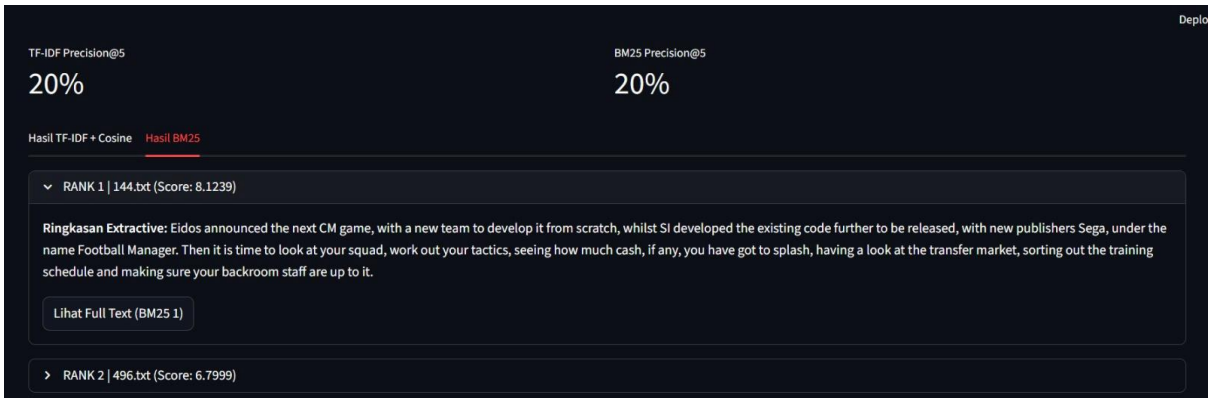
Demonstrasi sistem dilakukan secara langsung dengan menjalankan program melalui website. Pengguna memasukkan query teks, kemudian sistem menampilkan ranking dokumen dan ringkasan secara real-time.



Gambar 9.3 demonstrasi sistem



Gambar 9.3 demonstrasi sistem



Gambar 9.3 demonstrasi sistem

10. Limitations & Future Improvement

10.1 Limitations

Meskipun sistem Information Retrieval yang dibangun telah memenuhi seluruh kebutuhan fungsional proyek, terdapat beberapa keterbatasan yang masih dimiliki oleh sistem, antara lain:

- Evaluasi relevansi belum menggunakan ground truth manual
- Belum mendukung semantic search

10.2 Future Improvement

Beberapa pengembangan lanjutan yang dapat dilakukan untuk meningkatkan kualitas sistem antara lain:

- Integrasi word embedding (Word2Vec / BERT)
- Evaluasi berbasis user relevance judgment
- Query expansion

Kesimpulan

Sistem Information Retrieval yang dikembangkan mampu melakukan pencarian dokumen teks secara efektif melalui tahapan preprocessing, pembangunan inverted index, dan penerapan model pembobotan kata. Seluruh dokumen berita berhasil direpresentasikan dalam bentuk fitur numerik sehingga dapat dibandingkan dengan query pengguna.

Metode TF-IDF dengan cosine similarity dan BM25 sama-sama mampu menghasilkan dokumen yang relevan. TF-IDF efektif dalam menangkap kesesuaian kata pada query, sedangkan BM25 lebih stabil dalam menangani perbedaan panjang dokumen. Penggunaan inverted index juga meningkatkan efisiensi pencarian dengan membatasi dokumen yang diproses.

Selain itu, fitur extractive text summarization membantu pengguna memahami isi dokumen hasil pencarian secara ringkas. Berdasarkan evaluasi menggunakan Precision@K dan MRR, sistem menunjukkan performa pencarian yang baik dan telah memenuhi kebutuhan fungsional serta ketentuan proyek Information Retrieval.